Revisión académica como Reviewer 2

Conferencia ICI2ST 2026 - Evaluación metodológica y rigor científico

Elemento	Detalle
Manuscrito evaluado	Neural Networks Midterm Report: Optimization and Multi-Objective Analysis for Phishing Detection
Autores	Aispur Santiago; Guano Mishell
Tema	Detección de phishing mediante red neuronal artificial y optimización multiobjetivo con Optuna/TPE
Conjunto de datos	CIC-Trap4Phish 2025, 19,997 páginas HTML, con distribución casi balanceada: 9,999 benignas y 9,998 maliciosas
Formato esperado por ICI2ST 2026	Plantilla MDPI, manuscrito en inglés de alta calidad, entre 8 y 14 páginas excluyendo referencias
Recomendación preliminar	Revisión mayor antes de envío formal

Resumen ejecutivo

El manuscrito aborda un problema pertinente dentro de seguridad informática y aprendizaje automático, y presenta una idea técnicamente valiosa: optimizar una red neuronal para detección de phishing considerando simultáneamente F1-score, tiempo de inferencia y tamaño del modelo. Sin embargo, en su estado actual requiere una revisión metodológica significativa antes de su envío formal a ICI2ST 2026. Los problemas principales se relacionan con el cumplimiento del formato MDPI y la extensión mínima exigida, la ausencia de una sección de Materials and Methods completamente reproducible, la falta de comparación con modelos alternativos, inconsistencias entre los resultados de la frontera de Pareto y la evaluación final, y una descripción insuficiente del protocolo de validación, temporización y análisis estadístico.

1. Cumplimiento con requisitos formales de ICI2ST 2026

Aspecto	Problema encontrado	Por qué es una debilidad	Recomendación concreta
Plantilla oficial	El manuscrito se presenta en formato tipo IEEE de dos columnas, no en la plantilla MDPI proporcionada para ICI2ST 2026.	La convocatoria indica que los envíos deben prepararse usando la plantilla MDPI. Un manuscrito fuera de plantilla puede no ser admitido al proceso de revisión.	Migrar el manuscrito al archivo .tex MDPI compartido, usando secciones como Abstract, Introduction, Materials and Methods, Results, Discussion, Conclusions, Data Availability y Conflicts of Interest cuando corresponda.
Idioma	El manuscrito está escrito en inglés, lo cual es positivo, pero se observan problemas de redacción técnica, frases informales y algunas inconsistencias gramaticales.	La convocatoria exige una traducción o redacción en inglés de alta calidad. La calidad lingüística afecta la claridad metodológica y la admisibilidad.	Realizar revisión profesional del inglés académico. Evitar frases conversacionales como 'What if we could actually...' y reemplazarlas por formulaciones científicas directas.
Extensión	El PDF actual tiene 5 páginas, mientras que la convocatoria requiere entre 8 y 14 páginas excluyendo referencias.	La extensión actual es inferior al mínimo solicitado, lo cual sugiere que faltan detalles metodológicos, comparativos y de discusión.	Expandir el trabajo hasta al menos 8 páginas en formato MDPI, incorporando metodología reproducible, benchmarking, análisis de sensibilidad, discusión

Aspecto	Problema encontrado	Por qué es una debilidad	Recomendación concreta
			de limitaciones y detalles de reproducibilidad.

2. Fortalezas identificadas del trabajo

- El problema de detección de phishing es relevante para los ejes de seguridad, privacidad, inteligencia artificial y tecnologías de software de ICI2ST.
- El uso de CIC-Trap4Phish 2025 aporta actualidad al estudio y permite trabajar con un dataset específico de páginas HTML para phishing.
- El manuscrito declara explícitamente el número total de muestras y la distribución de clases, lo cual facilita una primera evaluación de validez experimental.
- Se aplica una división estratificada en entrenamiento, validación y prueba, manteniendo balance de clases; además, el escalador se ajusta exclusivamente con datos de entrenamiento, lo cual es una buena práctica para prevenir data leakage.
- La formulación multiobjetivo es pertinente porque un detector práctico de phishing no solo debe ser preciso, sino también liviano y rápido.
- La comparación entre modelo baseline y modelo optimizado ayuda a demostrar el efecto de la optimización, aunque debe complementarse con modelos externos de referencia.
- Se incluye un enlace al repositorio con implementación, lo cual favorece la reproducibilidad si el código se documenta y se vincula adecuadamente en el manuscrito final.

3. Sección de Materials and Methods: necesidad de mayor reproducibilidad

La plantilla MDPI utilizada por ICI2ST 2026 requiere que la sección de Materials and Methods describa el estudio con suficiente detalle para que otros investigadores puedan replicar y construir sobre los resultados. Aunque el manuscrito contiene secciones de dataset, preprocessing, arquitectura y optimización, la metodología todavía no está presentada como un protocolo secuencial completamente reproducible.

Aspecto	Problema encontrado	Por qué representa una debilidad	Recomendación concreta
Falta un diagrama metodológico completo	El trabajo incluye información textual sobre dataset, escalamiento, arquitectura y optimización, pero no presenta un diagrama de flujo que conecte de forma secuencial recolección, filtrado, división, normalización, entrenamiento, validación, optimización y evaluación final.	Sin un flujo explícito, el lector no puede verificar con precisión en qué etapa se aplican las transformaciones ni cómo se evita el leakage entre entrenamiento, validación y prueba.	Incluir una Figura 1 en Materials and Methods con fases numeradas: (1) adquisición del dataset CIC-Trap4Phish 2025; (2) criterios de inclusión/exclusión; (3) extracción/selección de las 13 características HTML; (4) split estratificado 60/20/20; (5) ajuste de StandardScaler solo en entrenamiento; (6) entrenamiento baseline; (7) optimización Optuna/TPE; (8) selección por Pareto; (9) reentrenamiento final; (10) evaluación en test no usado durante tuning.
Muestra y justificación estadística insuficientes	Se declara un total de 19,997 muestras y balance casi perfecto, pero no se justifica por qué esa muestra es suficiente ni cómo se preserva la representatividad de phishing benigno/malicioso.	La validez externa del modelo depende de que el conjunto represente variabilidad real de páginas benignas y maliciosas, no solo patrones del dataset.	Agregar una tabla con número de muestras por clase en cada partición: entrenamiento, validación y prueba. Explicar si el dataset contiene dominios únicos, páginas duplicadas, variabilidad temporal, tipos de phishing y posibles sesgos de recolección.

Aspecto	Problema encontrado	Por qué representa una debilidad	Recomendación concreta
Criterios de inclusión/exclusión poco formales	Se menciona la eliminación de file_name y la conservación de 13 características, pero no se definen criterios formales para excluir variables o registros.	La falta de criterios impide evaluar si se removieron variables por leakage, por falta de valor predictivo o por razones computacionales.	Incluir una subsección 'Inclusion and Exclusion Criteria': incluir páginas HTML etiquetadas con label válido; excluir identificadores no predictivos, duplicados exactos, registros corruptos, páginas sin contenido HTML analizable y variables derivadas directamente de la etiqueta.
Arquitectura dinámica parcialmente justificada	Se describe una capa fija de 200 neuronas seguida de bloques variables, pero no se justifica teóricamente por qué se expande de 13 a 200 dimensiones ni por qué ese valor no se optimiza.	La capa fija puede dominar el tamaño del modelo y afectar la interpretación del objetivo 'minimizar tamaño'.	Justificar la capa de 200 unidades mediante experimentos preliminares o convertirla en hiperparámetro. Reportar número total de parámetros de baseline y de cada solución Pareto, no solo KB.
Validación cruzada ausente	El manuscrito usa un único split 60/20/20 y una submuestra del 40% del entrenamiento para tuning, pero no reporta validación cruzada estratificada.	Un único split puede producir resultados dependientes de la partición. Esto es especialmente relevante cuando las mejoras son relativamente pequeñas.	Usar validación cruzada estratificada de 5 pliegues dentro del conjunto de entrenamiento para evaluar configuraciones o, al menos, repetir el split con 5 semillas diferentes y reportar media ± desviación estándar.

3.1. Diagrama metodológico recomendado

Figura metodológica sugerida

CIC-Trap4Phish 2025 → verificación de etiquetas y duplicados → definición de criterios de inclusión/exclusión → extracción/selección de 13 características HTML → división estratificada train/validation/test → ajuste de StandardScaler solo con train → entrenamiento baseline → optimización Optuna/TPE en validación interna → selección de soluciones Pareto → reentrenamiento del modelo seleccionado con train completo → evaluación única en test → análisis estadístico y comparación con baselines externos.

4. Análisis comparativo de modelos: benchmarking insuficiente

El manuscrito compara principalmente una red neuronal baseline contra una versión optimizada mediante Optuna/TPE. Esta comparación es necesaria, pero no suficiente para demostrar que el enfoque propuesto es superior o ventajoso frente a alternativas más simples o ampliamente usadas en detección de phishing.

Aspecto	Problema encontrado	Por qué representa una debilidad	Recomendación concreta
Comparación limitada	Solo se reporta baseline ANN vs. modelo optimizado. No se comparan modelos clásicos ni métodos especializados para clasificación tabular.	En datasets tabulares con 13 características, modelos como Logistic Regression, Random Forest, XGBoost/CatBoost, SVM o k-NN pueden igualar o superar redes neuronales con menor complejidad.	Incluir al menos 3 modelos externos: Logistic Regression como baseline interpretable, Random Forest o XGBoost/CatBoost como modelo tabular fuerte, y SVM o k-NN como referencia clásica. Si se quiere tratar phishing como anomalía, añadir Isolation Forest o LOF como comparación exploratoria. Ver la posibilidad de autoencoders.
No se reporta complejidad	El trabajo reporta tamaño e inferencia para la red neuronal,	La propuesta multiobjetivo se justifica por eficiencia, por lo que	Reportar para cada modelo: F1, precision, recall, accuracy, AUC,

Aspecto	Problema encontrado	Por qué representa una debilidad	Recomendación concreta
computacional comparable	pero no establece el mismo protocolo para otros modelos.	todos los modelos deben compararse con las mismas métricas de costo.	tiempo de entrenamiento, tiempo de inferencia por muestra y por lote, tamaño en memoria, número de parámetros o estimadores, y hardware usado.
Superioridad no demostrada	La mejora frente al baseline es moderada y viene acompañada de un incremento sustancial del tamaño del modelo frente al baseline de 5.76 KB.	No basta afirmar que el modelo es deployable; debe demostrarse que la relación costo-beneficio supera alternativas simples.	Agregar una discusión: el modelo propuesto es superior solo si obtiene mejor F1 con costo razonable o si ofrece mejor trade-off en Pareto que los baselines externos.

4.1. Tabla comparativa sugerida para el manuscrito

Modelo	F1	Precision	Recall	Accuracy	AUC	Tiempo inferencia	Tamaño	Justificación
Logistic Regression								Baseline lineal interpretable para features tabulares.
Random Forest								Modelo robusto para variables tabulares y relaciones no lineales.
XGBoost/CatBoost o Gradient Boosting								Referencia fuerte para clasificación tabular.
SVM o k-NN								Referencia clásica para clasificación binaria.
Autoencoder / Isolation Forest / LOF								Usar solo si se formula un escenario de detección de anomalías.
ANN baseline	0.8578			0.8545		6.53e-7	5.76 KB	Referencia interna sin optimización.
ANN Optuna/TPE	0.8807			0.8833		0.002 us	100 KB	Modelo seleccionado por trade-off multiobjetivo.

5. Balanceo de datos y validez experimental

El manuscrito indica que el dataset está prácticamente balanceado: 9,999 muestras benignas y 9,998 maliciosas. Por tanto, a diferencia de otros problemas de ciberseguridad fuertemente desbalanceados, no parece necesario aplicar SMOTE o submuestreo en esta versión del estudio. No obstante, el manuscrito debe establecer de forma explícita una política de balanceo y evaluación para evitar sesgos si se incorporan nuevos datos o si se analizan escenarios más realistas con distribución desbalanceada.

Aspecto	Problema encontrado	Por qué representa una debilidad	Recomendación concreta
Balance casi perfecto, pero falta discusión	Se afirma que el dataset está balanceado y se usa split estratificado, pero no se discute cómo cambiaría la metodología si el despliegue real presenta	Un dataset balanceado puede sobreestimar el rendimiento en escenarios reales donde el phishing es menos frecuente.	Añadir un experimento adicional con distribución realista o al menos una discusión de impacto: evaluar precision-recall curve, threshold tuning y tasas de falsos positivos

Aspecto	Problema encontrado	Por qué representa una debilidad	Recomendación concreta
	más páginas benignas que phishing.		por cada 1,000 páginas benignas.
Uso potencial de técnicas de balanceo	El trabajo no usa SMOTE porque no lo necesita; sin embargo, la solicitud metodológica exige declarar cómo se aplicarían técnicas de balanceo si se usaran.	Aplicar SMOTE, oversampling o undersampling antes del split produciría leakage y evaluación sesgada.	Incluir explícitamente: cualquier resampling debe aplicarse solo al conjunto de entrenamiento, después del split estratificado; validación y test deben permanecer sin datos sintéticos ni submuestreo artificial.
Alternativas a SMOTE	No se discuten alternativas apropiadas para phishing y clasificación binaria.	SMOTE no siempre es adecuado para características tabulares derivadas de HTML; puede generar combinaciones artificiales poco realistas.	Considerar alternativas: class weights, focal loss, threshold moving, cost-sensitive learning, calibration, RandomUnderSampler solo en train, SMOTE/Borderline-SMOTE/ADASYN solo en train, o Tomek Links/ENN solo como limpieza de entrenamiento.

6. Rigor metodológico integral

Aspecto	Problema encontrado	Por qué representa una debilidad	Recomendación concreta
Hiperparámetros	La tabla de búsqueda define rangos, pero no justifica por qué se eligieron 30 trials, 1-4 capas, 32-256 neuronas, dropout 0-0.5, LR 1e-4 a 1e-2 y batch size 32/64/128.	Sin justificación, la búsqueda puede parecer arbitraria y difícil de reproducir.	Justificar rangos con literatura o pruebas piloto. Reportar número de épocas, early stopping, función de pérdida, semilla aleatoria, hardware, librerías y versiones.
Optimización multiobjetivo	Se usa TPE de Optuna para tres objetivos, pero no se describe con suficiente detalle cómo se define la dirección de cada objetivo ni cómo se selecciona la solución final.	La selección de Solution 5 debe ser reproducible y no subjetiva.	Incluir la función objetivo exacta, direcciones ['maximize', 'minimize', 'minimize'], criterio de selección final, y una métrica de distancia al punto ideal o score normalizado si se usa.
Tiempo de inferencia	Los valores reportados son extremadamente bajos o aparecen como 0.000 us en tablas, lo cual sugiere problemas de medición, redondeo o escala.	El tiempo de inferencia es uno de los objetivos principales; una medición imprecisa debilita toda la optimización.	Repetir medición con warm-up, al menos 1,000-10,000 iteraciones, cronómetro de alta resolución, batch sizes definidos, CPU/GPU especificado, y reportar media, desviación estándar e intervalo de confianza.
Inconsistencia de resultados	En una sección se selecciona Solution 5 con F1=0.8692, en la evaluación final se reporta F1=0.8807, y en conclusiones se vuelve a mencionar 0.8692 e incremento de 0.0114, mientras que la tabla VI indica incremento de 0.0229.	Estas inconsistencias reducen la confianza en los resultados y pueden ser observadas de forma crítica por revisores.	Separar claramente métricas de validación durante optimización y métricas de test final. Corregir abstract, resultados y conclusiones para que todos reporten los mismos valores y expliquen por qué cambian.
Tamaño del modelo	El modelo optimizado aumenta de 5.76 KB a 100 KB, pero se presenta como compacto sin discutir que es 17.36 veces más	Si uno de los objetivos es minimizar tamaño, la selección final debe justificar por qué se acepta ese incremento.	Comparar el modelo optimizado no solo contra Solution 6, sino también contra el baseline. Reportar si el aumento de tamaño se compensa

Aspecto	Problema encontrado	Por qué representa una debilidad	Recomendación concreta
	grande que el baseline.		por la mejora de F1 y si existen restricciones reales de memoria.
Análisis estadístico	No se reportan intervalos de confianza, desviación estándar ni pruebas de significancia.	Una mejora de F1=0.0229 puede ser relevante, pero debe validarse estadísticamente.	Repetir experimentos con varias semillas o validación cruzada estratificada. Reportar media ± desviación estándar y, si procede, prueba de McNemar o bootstrap para comparar modelos.
Métricas	Se reportan accuracy y F1, pero no siempre precision, recall, AUC, PR-AUC, tasa de falsos positivos y tasa de falsos negativos.	En phishing, falsos negativos y falsos positivos tienen costos distintos. Accuracy puede ocultar errores críticos.	Incluir matriz de confusión normalizada, precision, recall, F1, ROC-AUC, PR-AUC, FPR, FNR y análisis de umbral.
Reproducibilidad	El apéndice incluye un enlace a GitHub, pero el manuscrito no especifica ambiente computacional ni procedimiento exacto para reproducir tablas y figuras.	La reproducibilidad requiere código, datos, dependencias, seeds y comandos de ejecución.	Añadir sección 'Reproducibility Statement': Python, PyTorch, Optuna, scikit-learn, sistema operativo, CPU/GPU, archivo notebook, commit hash, seeds, y ruta exacta del dataset.

7. Observaciones específicas sobre resultados y discusión

- Diferenciar explícitamente entre resultados de validación usados por Optuna y resultados finales en el conjunto de prueba. La solución Pareto puede tener F1=0.8692 durante optimización, mientras que el reentrenamiento final puede alcanzar F1=0.8807; esta diferencia debe explicarse.
- El objetivo 'minimizar inference time' parece no discriminar soluciones porque todas reportan tiempos menores a 1 microsegundo. Si el objetivo no discrimina, debe reconsiderarse la métrica de costo, por ejemplo FLOPs, número de parámetros, latencia por lote, energía estimada o memoria pico.
- La afirmación de que el modelo es adecuado para edge devices debe respaldarse con una evaluación en un entorno real o simulado de despliegue, no solo con tamaño en KB.
- La discusión debe incorporar amenazas a la validez: sesgo del dataset, posible dependencia entre muestras, representatividad temporal, cambios en técnicas de phishing y generalización a páginas fuera de CIC-Trap4Phish 2025.
- Las figuras deben ajustarse a las reglas de MDPI: títulos completos, explicación de ejes, unidades claras, colores distinguibles, referencia en el texto y resolución suficiente. En formato MDPI no basta con migrar el contenido; las figuras deben integrarse con caption descriptivo y análisis interpretativo.

8. Estructura recomendada para la versión MDPI de ICI2ST 2026

Sección MDPI	Contenido recomendado
Title	Mantener un título claro, preferiblemente menos extenso y sin ambigüedad sobre el método: phishing detection + multi-objective neural optimization.
Abstract	Incluir objetivo, dataset, tamaño de muestra, método, métricas principales y conclusión. Evitar resultados no consistentes.
Introduction	Plantear brecha científica: modelos de phishing que balancean rendimiento y deployability.
Materials and Methods	Incluir dataset, criterios de inclusión/exclusión, split, preprocessing, arquitectura, baseline, optimización, validación cruzada y protocolo de evaluación.

Sección MDPI	Contenido recomendado
Results	Presentar resultados por baseline, modelos comparativos, Pareto, modelo final y análisis estadístico.
Discussion	Interpretar hallazgos frente a literatura y discutir trade-offs, limitaciones y amenazas a la validez.
Conclusions	Resumir contribución sin exagerar generalización; mencionar trabajo futuro.
Data Availability / Code Availability	Indicar dataset público, repositorio, commit y condiciones de uso.

9. Ejemplos de redacción sugerida para incorporar al manuscrito

Texto sugerido para evitar leakage

All preprocessing transformations were fitted exclusively on the training set. The same fitted parameters were then applied to the validation and test sets. No resampling, synthetic data generation, feature selection based on test statistics, or threshold tuning was performed using the test set.

Texto sugerido para protocolo de inferencia

Inference time was measured after 100 warm-up iterations and averaged over 10,000 repeated predictions using a fixed batch size. Results are reported as mean ± standard deviation on the same hardware platform used for all models.

Texto sugerido para selección Pareto

The final solution was selected from the Pareto front using a normalized distance-to-ideal criterion, where the ideal point corresponds to maximum F1-score, minimum inference time, and minimum model size. This criterion ensures reproducible model selection rather than subjective visual inspection.

10. Recomendación final del Reviewer 2

Recomendación: Revisión mayor antes del envío formal

El trabajo tiene potencial para ICI2ST 2026 por su pertinencia temática y por combinar detección de phishing con optimización multiobjetivo. No obstante, no está listo para envío formal en su estado actual. Debe migrarse a formato MDPI, alcanzar la extensión mínima de 8 páginas excluyendo referencias, reforzar Materials and Methods para reproducibilidad completa, añadir benchmarking con modelos alternativos, corregir inconsistencias numéricas y robustecer la evaluación estadística. Si estas mejoras se implementan, el manuscrito podría convertirse en una contribución sólida para una conferencia enfocada en sistemas de información, seguridad, inteligencia artificial y tecnologías de software.

11. Checklist priorizado de acciones para los autores

1. Migrar el documento al template MDPI oficial de ICI2ST 2026.
2. Ampliar el manuscrito a 8-14 páginas excluyendo referencias.
3. Agregar un diagrama de flujo metodológico completo y reproducible.
4. Reportar tabla de distribución train/validation/test con número de muestras por clase.
5. Definir criterios de inclusión y exclusión de muestras y variables.
6. Añadir validación cruzada estratificada o experimentos con múltiples semillas.
7. Incluir comparación con Logistic Regression, Random Forest/Gradient Boosting y SVM/k-NN; opcionalmente Isolation Forest/LOF si se formula un escenario de anomalías.
8. Corregir todas las inconsistencias entre Solution 5, evaluación final y conclusiones.

9. Recalcular tiempos de inferencia con protocolo robusto y reportar media ± desviación estándar.
10. Justificar rangos de hiperparámetros y el número de trials de Optuna.
11. Discutir alternativas a SMOTE y establecer que cualquier balanceo debe aplicarse solo al conjunto de entrenamiento.
12. Agregar declaración de disponibilidad de datos/código, librerías, versiones, hardware y semillas aleatorias.

12. Fuentes utilizadas para esta revisión

- Manuscrito evaluado: Neural Networks Midterm Report: Optimization and Multi-Objective Analysis for Phishing Detection.
- Archivo .tex compartido por el usuario: plantilla MDPI de la conferencia.
- Captura de pantalla compartida por el usuario: notas importantes de ICI2ST 2026 sobre uso obligatorio de plantilla MDPI, idioma inglés y extensión de 8 a 14 páginas.
- Página oficial consultada: https://ici2st.epn.edu.ec/es/call-for-papers/